Анализ и прогнозирование потребления домашних хозяйств в регионах России

Итоговый проект по дисциплине «Временные ряды». Данные Росстата: фактическое конечное потребление домашних хозяйств на душу населения по субъектам РФ за 2000-2023 годы в текущих рыночных ценах, рублей. Код и все расчёты находятся в ноутбуке ts_final_project.ipynb, в отчёте приведены его графики и таблицы.

Этап 1. Загрузка и подготовка данных

Значения с десятичной запятой и пропуски («…», пустые ячейки) приведены к числам. В названии Калининградской области стоит латинская буква p вместо кириллической, название исправлено, иначе регион не находился бы по имени.

Пропуски нашлись у 8 территорий: у Крыма и Севастополя нет 14 лет, у двух записей «без автономных округов» нет 11 лет, у Чеченской Республики 5 лет, у Ненецкого, Ханты-Мансийского и Ямало-Ненецкого автономных округов по 3 года. Длинные начальные куски ряда не восстанавливались, такие территории исключены.

Из анализа исключено 17 территорий: строка по РФ в целом, 8 федеральных округов, 2 дублирующие записи и 6 субъектов с неполным рядом. Архангельская и Тюменская области с автономными округами оставлены: сами округа выпали из-за пропусков, поэтому двойного счёта нет.

Таблица 1. Исключённые территории и причины исключения

территория	причина
Фактическое конечное потребление домашних хозяйств на территории субъектов Российской Федерации – всего	РФ в целом
Центральный федеральный округ	федеральный округ
Северо-Западный федеральный округ	федеральный округ
Ненецкий автономный округ	неполный ряд, нет 3 лет
Архангельская область без автономного округа	дублирующая запись
Южный федеральный округ	федеральный округ
Республика Крым	неполный ряд, нет 14 лет
г. Севастополь	неполный ряд, нет 14 лет
Северо-Кавказский федеральный округ	федеральный округ
Чеченская Республика	неполный ряд, нет 5 лет
Приволжский федеральный округ	федеральный округ
Уральский федеральный округ	федеральный округ
Ханты-Мансийский автономный округ – Югра	неполный ряд, нет 3 лет
Ямало-Ненецкий автономный округ	неполный ряд, нет 3 лет
Тюменская область без автономных округов	дублирующая запись
Сибирский федеральный округ	федеральный округ
Дальневосточный федеральный округ	федеральный округ

Ошибка в данных

Ряды оставшихся субъектов проверены на одногодичные выбросы правилом: рост больше чем в 1.5 раза, а на следующий год падение ниже 0.8 от достигнутого. Правило

нашло одну точку. У Красноярского края в 2004 году записано 167 593.2 рубля при 54 406.4 в 2003 и 78 279.6 в 2005: рост в 3.08 раза и сразу 0.47 от достигнутого.

Это ошибка в данных, а не реальный скачок. Потребление на душу в текущих ценах растёт вместе с ценами и доходами, и вырасти втрое за год, а через год вернуться на прежнюю траекторию оно не может. Значение 2004 года заменено линейной интерполяцией по соседним годам, то есть их средним: 66 343.0 рубля. Задание запрещает восстанавливать длинные начальные фрагменты ряда, а здесь заменена одна точка внутри ряда, и с обеих сторон от неё стоят фактические значения.

Оставшиеся 79 субъектов переведены в длинный формат: по одной строке на каждую пару из региона и года, всего 1896 строк. Из неё для каждого региона собран отдельный ряд с годовым индексом. Пропусков в 79 рядах нет.

Вывод. Для анализа есть 79 субъектов с полными рядами за 24 года, без пропусков и без агрегатов, ошибочное значение Красноярского края за 2004 год исправлено.

Этап 2. Кластерный анализ регионов

Признаки

Данные в текущих ценах, поэтому абсолютное среднее и стандартное отклонение в основном отражают масштаб региона и инфляцию. Чтобы группы различались характером динамики, все пять признаков взяты относительными:

- коэффициент вариации (cv);
- средний годовой темп роста CAGR (cagr);
- отношение значения 2023 года к 2000 году (ratio_2023_2000);
- максимальное годовое падение, то есть минимальный годовой прирост (max_drop);
- доля лет со снижением (share_down).

У большинства регионов потребление в текущих ценах не снижалось ни разу, поэтому max_drop у них положительный и показывает самый слабый годовой прирост.

Кластеризация

Признаки стандартизированы StandardScaler: иначе отношение 2023/2000 с разбросом от 11.772 до 51.310 перевесило бы доли и коэффициенты. Использован K-means: признаков мало, все числовые, а центр кластера легко описать средними значениями признаков. Варианты k = 2, 3, 4 посчитаны с n_init=50 и random_state=42.

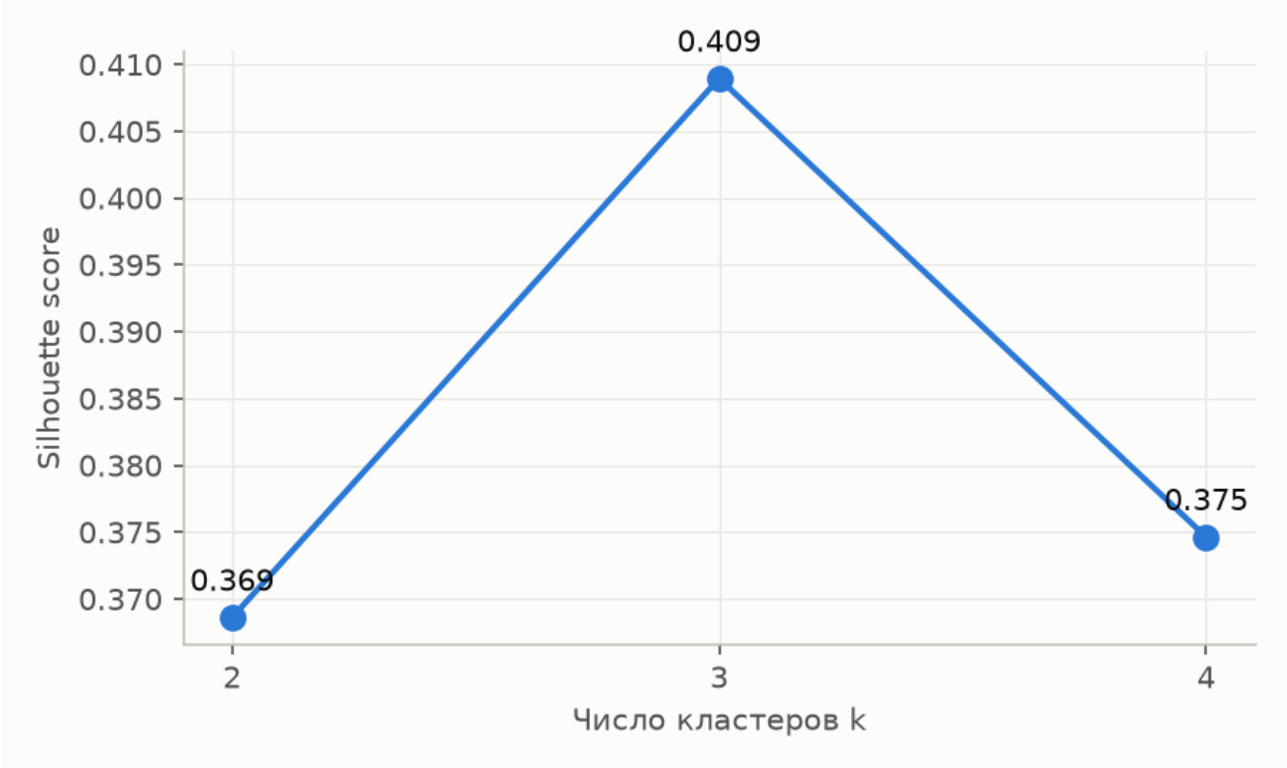


Рисунок 1. Silhouette score при k = 2, 3, 4

Таблица 2. Silhouette score и размер наименьшего кластера

k	силуэт	мин. размер кластера
2	0.369	28
3	0.409	15
4	0.375	6

Для прогноза нужны три региона из разных кластеров, поэтому выбор шёл между k=3 и k=4; в обоих вариантах в каждом кластере не меньше 3 регионов. Взято k=3: силуэт у него выше (0.409 против 0.375), а три группы ясно различаются темпом роста и тем, были ли годы снижения.

Описание кластеров

Таблица 3. Средние признаки и уровень потребления по кластерам (средний уровень: среднее за 2000-2023 годы; уровень 2000 и уровень 2023: среднее по кластеру в этом году, рублей)

кластер	регионов	CV	CAGR	2023 / 2000	макс. падение	доля лет снижения	средний уровень	уровень 2000	уровень 2023
1	18	0.660	0.141	21.067	0.004	0.010	240 781	29 350	574 477
2	15	0.697	0.159	30.409	-0.023	0.046	203 429	17 164	502 101
3	46	0.740	0.160	30.550	0.031	0.000	200 043	17 121	519 919

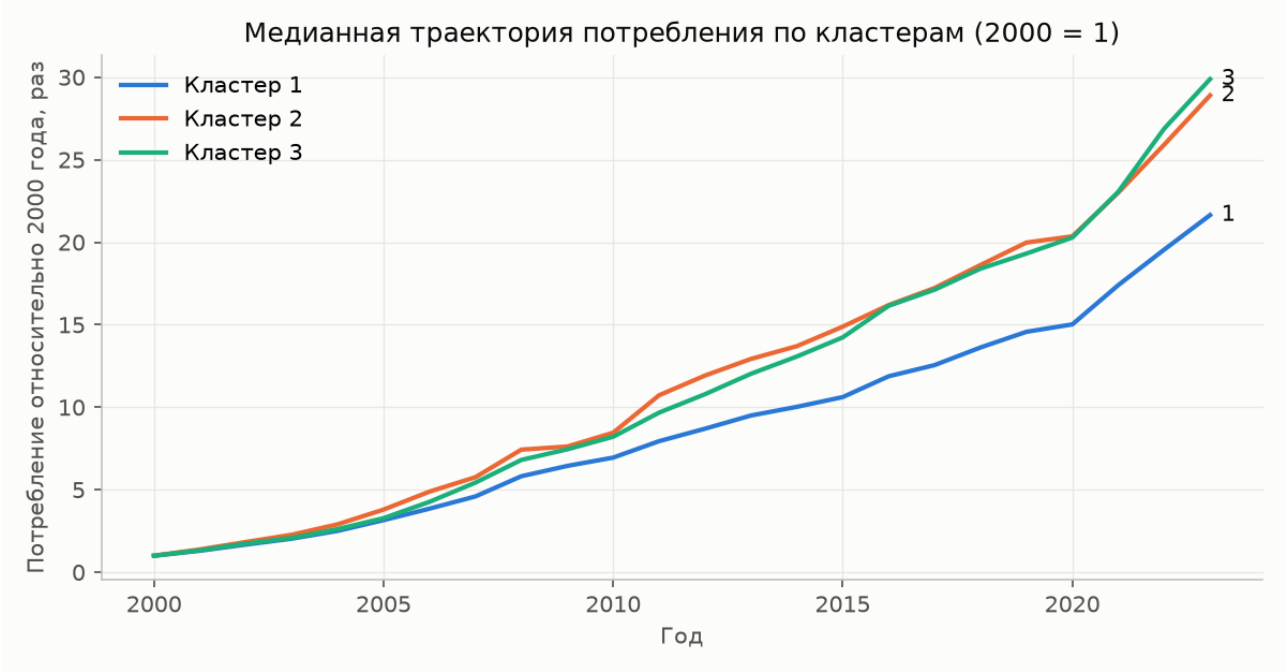


Рисунок 2. Медианная траектория потребления по кластерам, 2000 год = 1

• Кластер 1 (18 регионов: Москва, Тюменская область, Республика Коми, Якутия, Красноярский край и другие): регионы с высоким стартовым уровнем, в среднем 29 350 рублей в 2000 году против 17 164 и 17 121 у кластеров 2 и 3. Средний уровень самый высокий, 240 781 рубль, а рост самый медленный: в 21.1 раза при CAGR 14.1%.
• Кластер 2 (15 регионов: Ростовская, Свердловская, Челябинская, Кемеровская области и другие) вырос в 30.4 раза при CAGR 15.9%, но в среднем 4.6% лет у него со снижением, а максимальное годовое падение в среднем 2.3%. Средний уровень 203 429 рублей.
• Кластер 3 (46 регионов) растёт так же быстро, как кластер 2, в 30.6 раза при CAGR 16.0%, но без лет снижения, минимальный годовой прирост в среднем 3.1%. Средний уровень самый низкий, 200 043 рубля.

Таблица 4. Состав кластеров

кластер	регионов	состав
1	18	Астраханская область, Вологодская область, Иркутская область, Камчатский край, Карачаево-Черкесская Республика, Красноярский край, Мурманская область, Новгородская область, Новосибирская область, Пермский край, Республика Башкортостан, Республика Коми, Республика Саха (Якутия), Самарская область, Смоленская область, Томская область, Тюменская область, г. Москва
2	15	Алтайский край, Воронежская область, Забайкальский край, Кемеровская область, Курганская область, Омская область, Приморский край, Республика Дагестан, Республика Калмыкия, Ростовская область, Свердловская область, Ставропольский край, Тамбовская область, Челябинская область, Чукотский автономный округ

кластер	регионов	состав
3	46	Амурская область, Архангельская область, Белгородская область, Брянская область, Владимирская область, Волгоградская область, Еврейская автономная область, Ивановская область, Кабардино-Балкарская Республика, Калининградская область, Калужская область, Кировская область, Костромская область, Краснодарский край, Курская область, Ленинградская область, Липецкая область, Магаданская область, Московская область, Нижегородская область, Оренбургская область, Орловская область, Пензенская область, Псковская область, Республика Адыгея, Республика Алтай, Республика Бурятия, Республика Ингушетия, Республика Карелия, Республика Марий Эл, Республика Мордовия, Республика Северная Осетия – Алания, Республика Татарстан, Республика Тыва, Республика Хакасия, Рязанская область, Саратовская область, Сахалинская область, Тверская область, Тульская область, Удмуртская Республика, Ульяновская область, Хабаровский край, Чувашская Республика, Ярославская область, г. Санкт-Петербург

Вывод. Регионы с высоким уровнем потребления в 2000 году (кластер 1, в среднем 29 350 рублей) выросли меньше, в 21.1 раза, а регионы с низким стартом (кластеры 2 и 3, 17 164 и 17 121 рубль) быстрее, в 30.4-30.6 раза. Кластеры 2 и 3 различаются тем, были ли годы снижения.

Этап 3. Выбор регионов для детального прогнозирования

Кластеров три, поэтому из каждого взят один регион: ближайший к центру кластера в стандартизованном пространстве признаков.

Таблица 5. Признаки выбранных регионов и расстояние до центра кластера

регион	CV	CAGR	2023 / 2000	макс. падение	доля лет снижения	кластер	расст. до центра	место в кластере
Красноярский край	0.658	0.138	19.582	0.005	0.000	1	0.607	1
Ростовская область	0.714	0.158	29.447	-0.020	0.043	2	0.427	1
Курская область	0.737	0.160	30.467	0.031	0.000	3	0.078	1

- Красноярский край ближе всех к центру кластера 1: расстояние 0.607 при среднем по кластеру 1.547. Рост в 19.6 раза, CAGR 13.8%, ни одного года снижения. Регион входит в кластер с высоким стартовым уровнем (в среднем по кластеру 29 350 рублей в 2000 году).
- Ростовская область ближе всех к центру кластера 2: расстояние 0.427 при среднем 1.552. Рост в 29.4 раза, CAGR 15.8%, одно снижение на 2.0%, как и у кластера в целом.
- Курская область ближе всех к центру кластера 3: расстояние 0.078 при среднем 1.095. Рост в 30.5 раза, CAGR 16.0%, минимальный годовой прирост 3.1%, все признаки почти совпадают со средними кластера.

Вывод. Выбраны три региона с разными типами динамики: медленный рост с высокого уровня, быстрый рост с годом снижения и быстрый ровный рост с низкого уровня.

Этап 4. Анализ выбранных регионов

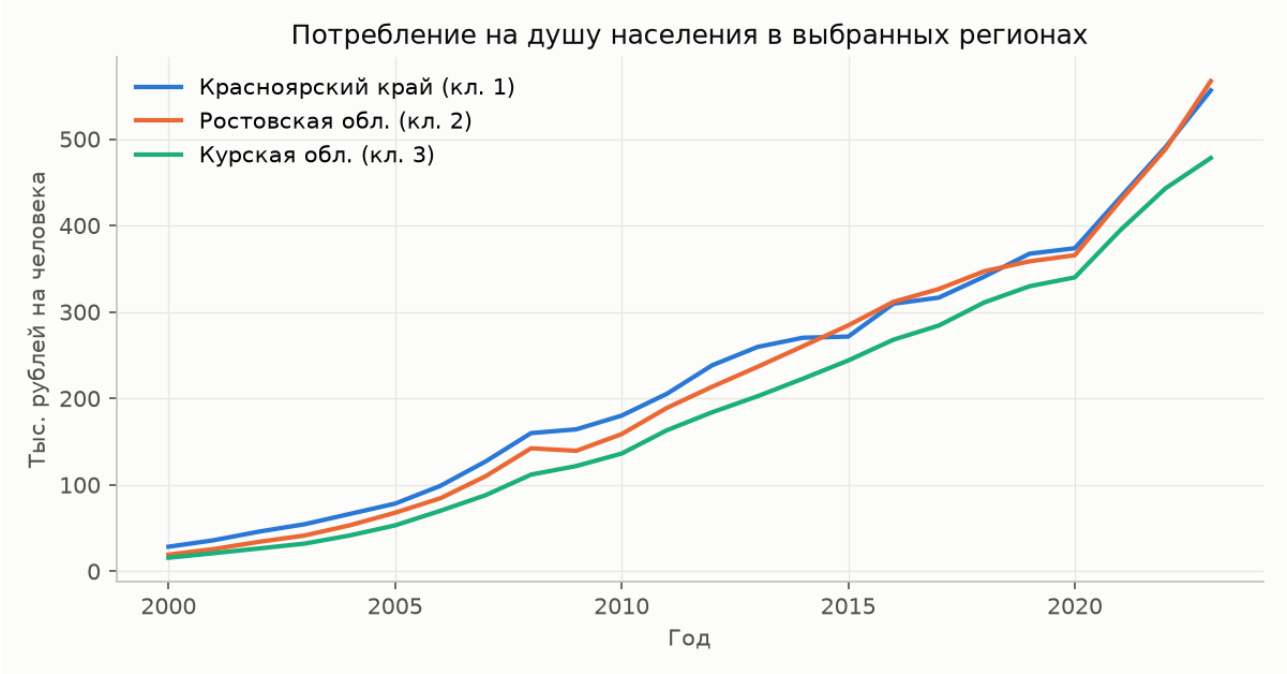


Рисунок 3. Потребление на душу населения в выбранных регионах

На рисунке 3 у всех трёх рядов восходящий тренд, который после 2020 года становится круче. Данные годовые, по одной точке на год, поэтому внутригодовой сезонности в них нет и сезонную компоненту выделять не из чего.

Стационарность проверена тестом Дики-Фуллера (adfuller, autolag='AIC') на уровнях, первых и вторых разностях полного ряда 2000-2023.

Таблица 6. Тест Дики-Фуллера для уровней и разностей

регион	ряд	ADF	p-value
Красноярский край	уровни	3.704	1.000
Красноярский край	1-я разность	-0.107	0.949
Красноярский край	2-я разность	-0.055	0.954
Ростовская область	уровни	1.963	0.999
Ростовская область	1-я разность	-1.182	0.681
Ростовская область	2-я разность	-5.693	0.000
Курская область	уровни	4.627	1.000
Курская область	1-я разность	-0.775	0.826
Курская область	2-я разность	-0.339	0.920

На уровнях p-value не ниже 0.999, гипотеза о единичном корне не отвергается, ряды нестационарны и содержат тренд. Разности по каждому региону:

- Красноярский край: на полном ряду нестационарны первая и вторая разности (p=0.949 и 0.954), на train вторая разность тоже нестационарна (p=0.826, таблица 7).
- Ростовская область: первая разность нестационарна (p=0.681), вторая стационарна (p=0.000), как и на train.
- Курская область: на полном ряду нестационарны обе разности (p=0.826 и 0.920), хотя на train первая разность стационарна (p=0.037). В полный ряд входит ускорение роста 2021-2023 годов, которое видно на рисунке 3, а в train его нет.

Поэтому порядок d для ARIMA подбирается на этапе 5 тем же тестом, но только на train.

Вывод. Все три ряда нестационарны на уровнях и содержат восходящий тренд.

Этап 5. Прогнозирование

Схема

Обучающая выборка охватывает 2000-2018 годы (19 лет, 79% ряда), тестовая 2019-2023 годы (5 лет). Горизонт прогноза на будущее одинаков для всех регионов: 5 лет, 2024-2028 годы. Модели:

- Holt из statsmodels с аддитивным трендом и оценкой начальных значений;
- ARIMA: d по тесту Дики-Фуллера на train, p и q от 0 до 2 перебором по AIC на train;
- наивный прогноз NaiveForecaster(strategy="last") из sktime как бейзлайн.

Тестовые годы в выборе порядка d не участвуют: тест Дики-Фуллера повторён только на train 2000-2018, d равен числу разностей, после которого p-value меньше 0.05.

Таблица 7. Тест Дики-Фуллера на train 2000-2018 для выбора d

регион	ряд	ADF	p-value
Красноярский край	уровни	-2.329	0.163
Красноярский край	1-я разность	-1.265	0.645
Красноярский край	2-я разность	-0.778	0.826
Ростовская область	уровни	1.947	0.999
Ростовская область	1-я разность	-0.698	0.847
Ростовская область	2-я разность	-2.884	0.047
Курская область	уровни	1.132	0.995
Курская область	1-я разность	-2.973	0.037
Курская область	2-я разность	-2.500	0.115

У Курской области стационарна первая разность (p=0.037), d=1. У Ростовской области стационарна вторая разность (p=0.047), d=2. У Красноярского края p-value 0.826 и после вторых разностей. Взято d=2: на 19 годовых точках train разности выше второй не берутся, а мощность теста Дики-Фуллера на таком коротком ряду мала, и неотвергнутый единичный корень ещё не значит, что нужна третья разность.

По AIC на train выбраны ARIMA(0,2,1) для Красноярского края и Ростовской области и ARIMA(1,1,0) для Курской области.

Качество на test

Таблица 8. RMSE (рублей) и MAPE (%) на 2019-2023 годах

регион	модель	RMSE	MAPE, %
Красноярский край	Naive	125 731	21.3
Красноярский край	Holt	70 590	10.4
Красноярский край	ARIMA	69 619	10.2
Ростовская область	Naive	122 816	19.0
Ростовская область	Holt	66 016	9.9
Ростовская область	ARIMA	58 642	9.0
Курская область	Naive	103 408	20.0
Курская область	Holt	31 391	6.0

регион	модель	RMSE	MAPE, %
Курская область	ARIMA	42 353	7.6

Обе статистические модели заметно лучше наивного прогноза: MAPE 6.0-10.4% против 19.0-21.3%. Лучшая модель выбрана по RMSE:

- Красноярский край: ARIMA(0,2,1), RMSE 69 619.4, MAPE 10.2% (у Holt 70 590.3 и 10.4%);
- Ростовская область: ARIMA(0,2,1), RMSE 58 641.6, MAPE 9.0% (у Holt 66 015.9 и 9.9%);
- Курская область: Holt, RMSE 31 390.8, MAPE 6.0% (у ARIMA(1,1,0) 42 353.2 и 7.6%).

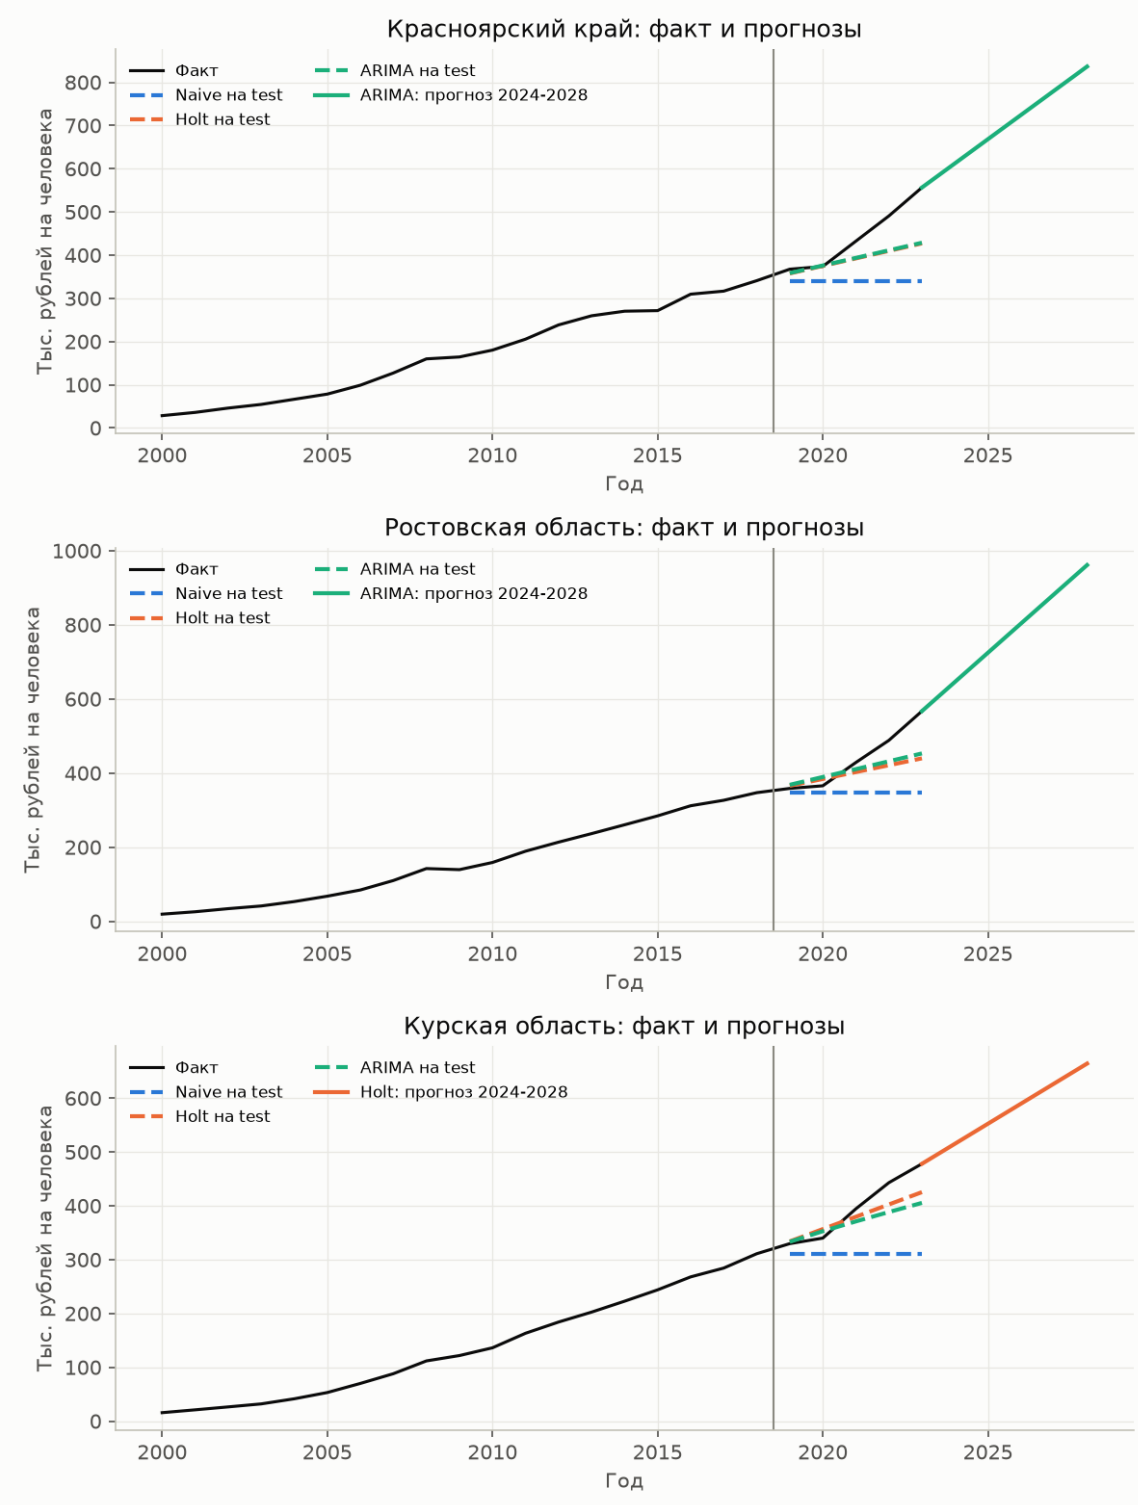


Рисунок 4. Факт, прогнозы на test и прогноз лучшей модели на 2024-2028 годы

На рисунке 4 у Красноярского края прогнозы Holt и ARIMA на test почти совпадают, линии накладываются. Все модели занижают 2021-2023 годы: они продолжают линейный тренд train, а рост в эти годы ускорился. В Ростовской области ARIMA выигрывает у Holt (RMSE 58 641.6 против 66 015.9): на графике ARIMA с d=2 даёт на test линию круче, чем у Holt, и поэтому меньше занижает 2021-2023 годы. В Курской области ARIMA(1,1,0) с d=1 продолжает более пологий тренд, чем Holt, и занижает test сильнее.

Прогноз на 2024-2028 годы

Лучшая модель каждого региона переобучена на всём ряду 2000-2023. Для Ростовской области на всём ряду по AIC выбрана ARIMA(0,2,0): она продолжает прирост 2023 года, +78.8 тыс. рублей в год. Для Красноярского края осталась ARIMA(0,2,1).

Таблица 9. Прогноз лучшей модели на 2024-2028 годы, рублей на человека

год	Красноярский край	Ростовская область	Курская область
2024	612 344	645 859	515 266
2025	668 349	724 687	552 507
2026	724 355	803 514	589 748
2027	780 360	882 342	626 988
2028	836 366	961 169	664 229

Таблица 10. Итог прогноза: значение 2023 и 2028 годов, прирост за 5 лет и средний годовой прирост, %

регион	модель	2023	2028	рост 2028/2023, %	в год, %
Красноярский край	ARIMA	556 338	836 366	50.3	8.5
Ростовская область	ARIMA	567 032	961 169	69.5	11.1
Курская область	Holt	478 026	664 229	39.0	6.8

Вывод. По лучшей модели к 2028 году потребление вырастет на 50.3% в Красноярском крае (до 836 366 рублей), на 69.5% в Ростовской области (до 961 169) и на 39.0% в Курской области (до 664 229).

Этап 6. Анализ ошибок

Здесь разбираются ошибки подгонки лучшей модели, оценённой на всём ряду: одношаговые прогнозы внутри выборки с параметрами по всему ряду. Для Ростовской области это ARIMA(0,2,0), выбранная по AIC на всём ряду, для Красноярского края ARIMA(0,2,1), для Курской области Holt. Первые два года не учитываются, потому что у модели там ещё нет истории для оценки тренда. Ошибка считается в процентах от факта, плюс означает, что модель занизила значение.

Таблица 11. Топ-5 лет с наибольшей ошибкой лучшей модели

регион	год	факт	прогноз	ошибка, %
Красноярский край	2009	164 230	186 935	-13.8
Красноярский край	2021	432 207	388 631	10.1
Красноярский край	2007	127 141	114 669	9.8
Красноярский край	2006	98 846	89 646	9.3

регион	год	факт	прогноз	ошибка, %
Красноярский край	2016	309 547	281 164	9.2
Курская область	2006	70 005	62 328	11.0
Курская область	2021	394 357	356 607	9.6
Курская область	2008	111 829	102 767	8.1
Курская область	2002	26 422	28 511	-7.9
Курская область	2004	41 464	38 242	7.8
Ростовская область	2009	139 375	174 505	-25.2
Ростовская область	2010	158 695	136 475	14.0
Ростовская область	2021	428 455	372 672	13.0
Ростовская область	2004	53 199	48 630	8.6
Ростовская область	2007	110 045	101 224	8.0

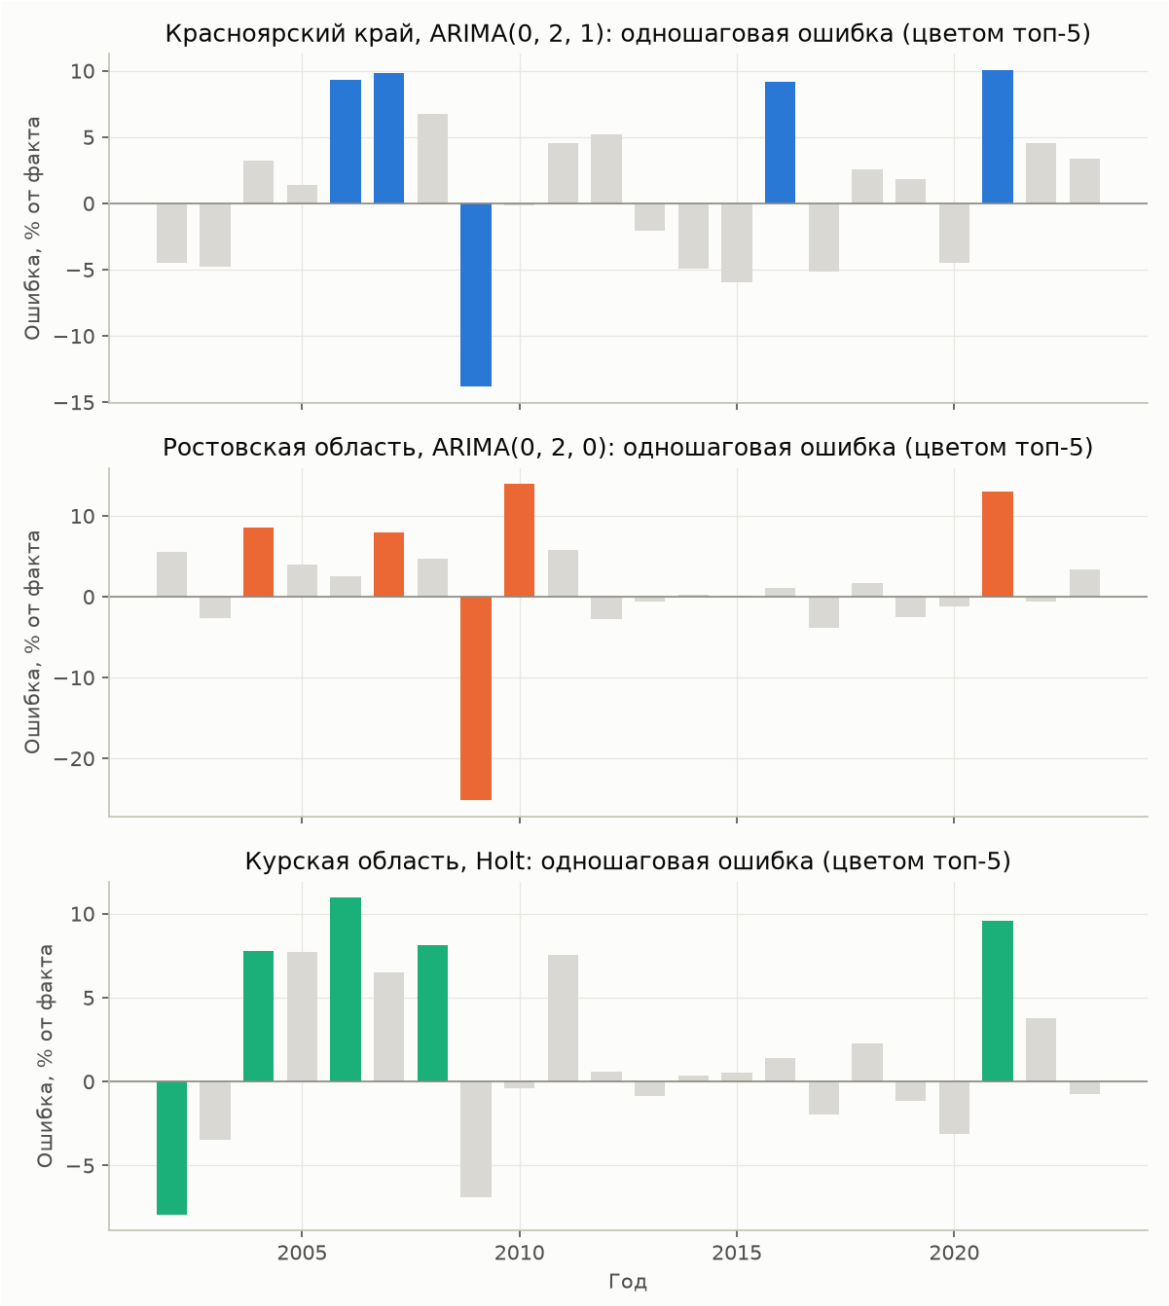


Рисунок 5. Одношаговая ошибка лучшей модели по годам, цветом выделены топ-5

У Ростовской области наибольшая ошибка в 2009 году: -25.2%, модель ждала 174 505 рублей, а факт 139 375. У Красноярского края в 2009 году тоже переоценка, -13.8%. У Курской области все ошибки из топ-5 не выше 11.0%.

Таблица 12. Годовой прирост потребления в годы, с которыми связаны гипотезы об ошибках, %

регион	2009	2010	2015	2016	2020	2021
Красноярский край	2.8	9.7	0.5	14.0	1.7	15.7
Ростовская область	-2.0	13.9	9.2	9.6	2.0	17.2
Курская область	8.9	11.8	9.5	9.9	3.1	16.0

Гипотезы о причинах ошибок:

- 2008-2009 годы: кризис остановил рост доходов, а модели продолжили докризисный тренд, отсюда переоценка 2009 года. В Ростовской области потребление в 2009 году снизилось на 2.0%, а следом модель недооценила восстановление 2010 года (+14.0%).
- 2015-2016 годы: после падения цен на нефть и девальвации рост в Красноярском крае в 2015 году почти остановился (прирост 0.5%), а в 2016 году вернулся (14.0%), и модель занизила 2016 год (+9.2%).
- 2020-2021 годы: в 2020 году рост замедлился (прирост 1.7-3.1%), а в 2021 году потребление выросло на 15.7-17.2% на фоне восстановления и ускорения инфляции, поэтому 2021 год занижен во всех трёх регионах (от +9.6% до +13.0%).
- 2006-2007 годы, а у Курской области и 2008 год: докризисный рост доходов шёл быстрее тренда, модели его занижали.
- 2002 и 2004 годы: короткая история, модели ещё не оценили тренд.

Вывод. Крупные ошибки приходятся на кризис 2009 года, восстановление 2021 года и докризисный рост 2006-2007 годов.

Этап 7. Индивидуальные рекомендации

Для рекомендаций взят прогноз лучшей модели на 2024-2028 годы и уровень 2023 года относительно среднего по 79 субъектам (528 967 рублей).

Таблица 13. Прогноз лучшей модели и уровень 2023 года относительно среднего по субъектам

регион	модель	2023	2028	рост 2028/2023, %	в год, %	2023 к среднему, %
Красноярский край	ARIMA	556 338	836 366	50.3	8.5	5.2
Ростовская область	ARIMA	567 032	961 169	69.5	11.1	7.2
Курская область	Holt	478 026	664 229	39.0	6.8	-9.6

Красноярский край

- По прогнозу потребление на душу вырастет с 556 338 рублей в 2023 году до 836 366 рублей в 2028 году, на 50.3%, или 8.5% в год, а уровень 2023 года на 5.2% выше среднего по 79 субъектам. Под этот темп стоит планировать торговые площади и социальные расходы края.
- Доходы населения края во многом зависят от цветной металлургии, лесной и добывающей отрасли, поэтому бюджетные и социальные программы края стоит проверять, помимо продолжения тренда, на сценарий падения мировых цен на

металлы.

Ростовская область

• Прогноз даёт рост с 567 032 рублей в 2023 году до 961 169 рублей в 2028 году, на 69.5%, или 11.1% в год. Уровень 2023 года на 7.2% выше среднего по субъектам. Модель переносит на будущее ускорение 2021-2023 годов, поэтому планы области по потребительскому рынку стоит строить на этом прогнозе как на верхней границе и пересматривать по фактическим данным каждого года.

• В кризис 2009 года потребление в Ростовской области снизилось, поэтому для области с крупным аграрным и транспортным комплексом юга стоит заранее готовить меры поддержки доходов на случай нового спада.

Курская область

• По Holt потребление вырастет с 478 026 рублей в 2023 году до 664 229 рублей в 2028 году, на 39.0%, или 6.8% в год. При этом в 2023 году область на 9.6% ниже среднего по субъектам, и программы поддержки доходов стоит нацелить на то, чтобы этот разрыв сокращался быстрее прогноза.

• Курская область аграрная и приграничная. Области стоит заранее зарезервировать маршруты и склады для снабжения приграничных районов и поддержать торговлю в этих районах, чтобы перебои с поставками не сокращали потребление.

Вывод. По прогнозу Красноярский край растёт на 8.5% в год, Ростовская область на 11.1%, Курская область на 6.8%. В 2023 году Красноярский край выше среднего по субъектам на 5.2%, Ростовская область на 7.2%, Курская область ниже на 9.6%. Рекомендации опираются на прогноз и положение каждого региона.

Этап 8. Выводы по проекту

По пяти относительным признакам динамики 79 субъектов разделились на 3 кластера (силуэт 0.409). Большой кластер 3 из 46 регионов вырос за 2000-2023 годы в 30.6 раза и ни разу не снижался. Кластер 2 из 15 регионов вырос так же, в 30.4 раза, но с отдельными годами снижения. Кластер 1 из 18 регионов, в том числе Москва и Тюменская область, стартовал с высокого уровня (в среднем 29 350 рублей в 2000 году) и вырос меньше, в 21.1 раза.

Для представителей кластера 1 (Красноярский край) и кластера 2 (Ростовская область) лучшей оказалась ARIMA(0,2,1), MAPE 10.2% и 9.0%. Для представителя кластера 3 (Курская область) лучше Holt с MAPE 6.0%, у ARIMA(1,1,0) 7.6%. Наивный прогноз проигрывает обеим моделям во всех регионах (MAPE 19.0-21.3%), так что тренд в рядах сильный и модели его улавливают. В одношаговых ошибках самые крупные промахи у Красноярского края и Ростовской области приходятся на кризис 2009 года (-13.8% и -25.2%), у Курской области на 2006 год (+11.0%).